Universidad Rafael Landívar

Facultad de Ingeniería

Ciencia de Datos

Sección 02

Ing. Max Alejandro Cerna Flores

Proyecto 2 - Red Metropolitana

Fase 2 - Modelos, decisión y producción

Héctor Pérez - 1304223

Alejandro Gil - 1187420

Jonatán Chávez - 1185023

José Carlos Avalos Pérez - 1315918

Guatemala, 9 de noviembre de 2026

1 Introducción y objetivo

La segunda fase del Proyecto 2 de Red Metropolitana utiliza los datos integrados del sistema de transporte para estimar qué tarjetas podrían dejar de registrar viajes durante los 30 días siguientes a una fecha de corte. El objetivo es comparar modelos predictivos, convertir sus probabilidades en una decisión de contacto económicamente justificable, identificar segmentos de movilidad e implementar una inferencia reproducible para el corte C.

El trabajo parte de las tablas Silver construidas en la fase anterior, conserva el grano de tarjeta por operador y distingue los datos disponibles antes del corte de los datos futuros utilizados para construir la etiqueta. Los resultados provienen de un conjunto académico simulado; por lo tanto, representan estimaciones bajo los supuestos del ejercicio, no retenciones reales observadas.

2 Metodología y control temporal

Unidad de análisis y construcción de los cortes

Se definió como unidad la tarjeta operacional, identificada por la combinación de operador y llave de tarjeta. La población incluye unidades con al menos dos usos válidos en los 28 días previos al corte y aplica las exclusiones históricas pertinentes del padrón CDC. La etiqueta es 1 cuando la unidad no presenta usos válidos en los 30 días posteriores y 0 cuando registra al menos uno; la etiqueta del corte C permanece oculta.

Corte	Fecha de corte	Tarjetas	Positivas	Tasa positiva
A	01/07/2026	77,411	11,211	11,211 / 77,411 = 14.48 %
B	31/07/2026	76,378	10,312	10,312 / 76,378 = 13.50 %
C	30/08/2026	76,420	No disponible	Sin etiqueta para inferencia

El corte A se reservó para entrenamiento, validación cruzada y selección del umbral. El corte B se utilizó exclusivamente una vez como prueba temporal independiente. En C se aplicaron el modelo y la política de contacto definidos previamente, sin utilizar resultados futuros ni realizar reajustes.

Variables y prevención de fugas

Se emplearon diez variables numéricas de frecuencia, recencia, actividad, gasto, tarifa, puntos de origen y proporciones horarias, más la variable categórica operador. Las ventanas son consistentes entre cortes y no exceden 28 días. Los viajes de MetroRiel requieren cierre y disponibilidad anteriores a la fecha de corte; los datos en cuarentena no se incorporan. La auditoría de recorte de la fase anterior registró cero diferencias para las features calculadas con datos completos y recortados.

3 Ensemble y sesgo-varianza (requisito 2.1)

Comparación de modelos

Se compararon dos líneas base, dos regresiones logísticas regularizadas y tres configuraciones de Random Forest. Se mantuvieron cinco folds estratificados, con semilla 2026 y los mismos predictores del modelo base. La métrica principal fue ROC-AUC, que permite comparar la capacidad para ordenar tarjetas según su riesgo de abandono a través de distintos umbrales.

Modelo	AUC entrenamiento	AUC validación	Brecha media
Tasa constante	0.500000	0.500000	0.000000
Recencia	0.795402	0.795401	0.000000
Logística L1	0.807063	0.806806	0.000257
Logística L2	0.807208	0.806967	0.000241
RF somero	0.821443	0.816470	0.004974
RF regularizado	0.854489	0.816965	0.037524
RF flexible	0.936477	0.806287	0.130190

Los valores son medias de validación cruzada. Las desviaciones estándar de ROC-AUC de validación fueron 0.003134 para logística L2 y 0.002437 para RF somero. El bosque flexible mostró una diferencia considerable entre entrenamiento y validación (0.130190), compatible con mayor sobreajuste; la logística mantuvo una brecha pequeña, aunque con menor poder discriminatorio.

Modelo recomendado

Se recomienda RF somero, con 100 árboles, profundidad máxima 6, mínimo de 50 muestras por hoja, bootstrap, criterio Gini, max_features=sqrt y semilla 2026. Su ROC-AUC de validación fue 0.816470, lo que supera a logística L2 en 0.009503. Aunque RF regularizado alcanzó una validación ligeramente superior (0.816965), su brecha fue mucho mayor (0.037524 frente a 0.004974). La mejora marginal no compensó esa diferencia de generalización y complejidad.

Importancia de variables por permutación en validación

Las importancias se calcularon permutando cada predictor sobre datos de validación, cinco veces por variable, con una muestra estratificada de hasta 4,000 tarjetas por fold. Una mayor caída del ROC-AUC indica mayor contribución al ordenamiento del riesgo en esta prueba; variables correlacionadas pueden compartir señal.

Variable	Caída media de ROC-AUC
dias_desde_ultimo_uso	0.054008
viajes_7d	0.016639
viajes_14d	0.008063
viajes_28d	0.004585
dias_activos_28d	0.002125
operador	0.001001
gasto_28d_gtq	0.000943
tarifa_media_gtq	0.000476
puntos_origen_28d	0.000289
proporcion_fin_semana	0.000181

La variable más relevante fue días desde el último uso, seguida por los viajes registrados en los últimos 7 y 14 días. El AUC agrupado de las predicciones fuera de fold (OOF) del modelo

recomendado fue 0.816293; este valor no reemplaza al promedio de AUC de los cinco folds usado para la comparación.

4 Umbral económico y test único B (requisito 2.2)

Cálculo de la ganancia y selección del umbral

La Agencia asume un costo de Q5 por contacto, una efectividad de retención del 25 % cuando el usuario habría abandonado y un valor de Q60 por usuario retenido. Por cada verdadero positivo contactado, el beneficio esperado antes del costo es 0.25 × Q60 = Q15. La ganancia total se expresa como:

$$G = Q15 \times TP - Q5 \times (TP + FP) = Q10 \times TP - Q5 \times FP$$

Con probabilidades perfectamente calibradas, el contacto presenta ganancia esperada positiva cuando $15p - 5 > 0$, es decir, $p > 1/3$. Sin embargo, el umbral operativo se determinó maximizando la ganancia empírica sobre 72,042 candidatos calculados únicamente con predicciones OOF de A. El valor quedó congelado en 0.311210473799652; la regla es contactar cuando puntaje ≥ umbral.

Resultados de la política en A y evaluación única en B

Indicador	A (OOF, selección)	B (test único)
Tarjetas	77,411	76,378
Contactos	10,625	9,844
Verdaderos positivos (TP)	4,664	4,070
Falsos positivos (FP)	5,961	5,774
Verdaderos negativos (TN)	60,239	60,292
Falsos negativos (FN)	6,547	6,242
Precisión	43.90 %	41.35 %
Recall	41.60 %	39.47 %
ROC-AUC agrupado	0.816293	0.813388
Ganancia esperada	Q16,835	Q11,830

El corte B se evaluó una sola vez, el 7 de noviembre de 2026 a las 16:53:50 (Guatemala), con la decisión fijada previamente y la versión de código registrada en el commit 9d84ad3fc88277fbb2ed94592fcba3dea6eb5eda. El modelo se había ajustado con todo A. No se seleccionaron nuevos hiperparámetros ni se modificó el umbral al consultar B.

La ganancia esperada de B resultó Q5,005 menor que la estimación OOF de A, mientras que precisión y recall también disminuyeron. El cambio de prevalencia entre cortes y la optimización del umbral sobre A pueden contribuir a esa diferencia; una única evaluación temporal no permite atribuirle una causa definitiva. La ganancia reportada es hipotética y no implica campañas o retenciones efectivamente ejecutadas.

5 Segmentación con KMeans y PCA (requisito 2.3)

Selección de grupos y visualización

La segmentación se realizó de manera independiente con las 77,411 tarjetas de A y las diez variables numéricas escaladas mediante StandardScaler. Se excluyeron identificadores, fechas, operador y la etiqueta de abandono del ajuste para evitar que la separación de grupos dependiera del resultado que se desea interpretar.

Se probaron valores de k entre 2 y 8. El método geométrico del codo sugirió k=4, mientras que la mayor silueta estimada en una muestra fija de 3,000 tarjetas fue 0.492947 para k=2 (frente a 0.227953 para k=4). Se adoptó k=2 conforme al criterio de máxima silueta. PCA explicó 50.70 % de la varianza con el primer componente y 14.64 % con el segundo, para un total de 65.35 %. El KMeans se ajustó en las diez dimensiones; PCA solo se empleó para visualizar.

Interpretación y acciones por segmento

Segmento	Tarjetas	Viajes 28d (med.)	Recencia (días)	Gasto med.	Abandono en A
S0: uso ocasional	69,027	6	3.77	Q9.00	11,055 / 69,027 = 16.02 %
S1: uso frecuente	8,384	40	0.41	Q61.10	156 / 8,384 = 1.86 %

S0 agrupa tarjetas con menor frecuencia de uso, pausas relativamente más largas y mayor proporción descriptiva de abandono. Se propone explorar recordatorios de retorno y recargas de incentivo limitadas. S1 reúne tarjetas con uso frecuente y reciente; se propone explorar beneficios por continuidad o abonos asociados a sus puntos habituales de origen. Estas intervenciones son hipótesis operativas y sus efectos no fueron evaluados experimentalmente.

6 MLOps e inferencia en C (requisito 2.4)

Modelo serializado y procedimiento

El Pipeline final v1_rf_somero se ajustó únicamente con las 77,411 tarjetas del corte A, manteniendo los once predictores, la configuración acordada en 2.1 y el umbral exacto congelado en 2.2. El archivo models/modelo_abandono_rf_somero_v1.joblib incluye el preprocesamiento y el clasificador. El script predecir.py lo carga y verifica sus metadatos; no reentrena ni consulta etiquetas de B o C.

La inferencia recibe una carpeta portable con seis CSV de fuentes Silver operacionales, CDC y cuarentena junto con un manifiesto de integridad. Las fuentes se cargan en tablas temporales de PostgreSQL y se recalculan población y features mediante las consultas de 1.2 y 1.3 con restricciones anteriores al corte. El procedimiento se documenta para Python 3.12 y PostgreSQL 16 con dependencias fijadas en requirements-inferencia.txt.

python predecir.py --datos datos_red --fecha-corte 2026-08-30

Predicciones publicadas del corte C

Indicador	Resultado
Corte utilizado	30 de agosto de 2026
Tarjetas evaluadas	76,420
Tarjetas marcadas para contactar	10,412
Archivo publicado	datos_red/p2-24-predicciones-c.csv
Columnas	unidad_id, tarjetas, puntaje, contactar
Criterio de contacto	puntaje ≥ 0.311210473799652

El CSV conserva una fila por unidad y utiliza en tarjetas la llave operacional original, sin sustituirla por un conteo. La evidencia registra cero unidades duplicadas, probabilidades dentro de [0, 1], el hash del artefacto y el hash del CSV final. El archivo y el modelo están versionados en el repositorio.

Prueba de invariancia temporal

Para comprobar la ausencia de información posterior al corte, se copiaron las entradas Silver y se agregaron 15,031 registros sintéticos correspondientes a los 30 días posteriores al 30 de agosto, incluidos nuevos movimientos, eventos CDC, cuarentena y un viaje MetroRiel cerrado después del corte. Se recalcularon las features y la inferencia sin alterar el modelo ni el umbral. El resultado registró 76,420 tarjetas, cero diferencias en identidades, variables, puntajes o decisiones, y un CSV idéntico byte a byte.

Esta validación cubre desde las fuentes Silver hasta el CSV de inferencia. La comprobación del flujo completo al recibir archivos Raw/Bronze adicionales del docente queda como prueba presencial de defensa; no se presenta como ya realizada. La evidencia del equipo reporta además 123 pruebas automatizadas aprobadas sin omisiones y una reproducción en un entorno virtual nuevo con PostgreSQL sin tablas Silver preexistentes.

Tiempos de ejecución medidos

Proceso	Tiempo registrado
Carga y cálculo de features A antes del ajuste	27.093 s
Ajuste del Random Forest en todo A	9.786 s
Entrenamiento y serialización total	37.179 s
Primera inferencia completa en C	76.682 s
Solo predict_proba de C	1.305 s

Los tiempos pertenecen al entorno en que el equipo ejecutó las pruebas y pueden variar en otras máquinas. Las versiones de librerías, hashes y comandos se conservan en los JSON y en la guía de reproducción del apartado 2.4.

7 Resultados generales y limitaciones

El trabajo estableció una cadena de decisión trazable: se partió de una población y features auditadas, se compararon modelos bajo validación cruzada, se eligió un Random Forest de baja complejidad relativa, se congeló un umbral basado en ganancia con datos OOF de A y se reservó B para una evaluación temporal única. Finalmente, se produjo y publicó el CSV de C con el mismo modelo y el mismo umbral.

Las principales limitaciones son el carácter simulado de los datos, la diferencia entre tarjeta y persona real, la imposibilidad de verificar identidades entre todos los operadores, la ausencia de calibración probabilística garantizada y el carácter descriptivo —no causal— de los segmentos. Las métricas de B reflejan un único periodo temporal y no constituyen garantía de desempeño futuro. La invariancia está respaldada en Silver y deberá demostrarse nuevamente con la ampliación oficial de datos durante la defensa.

8 Conclusión

La Fase 2 permitió transformar los registros de movilidad en un flujo analítico reproducible para identificar tarjetas con riesgo de inactividad. RF somero consiguió un ROC-AUC medio de validación de 0.816470 y un mejor equilibrio de complejidad y generalización que las alternativas más flexibles. Con la política económica congelada se obtuvo una ganancia esperada de Q11,830 en B, sin modificar el modelo después de abrir el test. La segmentación identificó dos patrones de uso diferenciados, y el componente MLOps produjo 76,420 predicciones para C, manteniendo resultados idénticos en la prueba documentada de invariancia temporal.

Con ello se cumplieron los entregables técnicos de entrenamiento, decisión, segmentación y producción. Las evidencias y resultados pueden reproducirse siguiendo los procedimientos del repositorio, con las advertencias metodológicas señaladas y la posterior demostración en vivo prevista por el docente.

9 Evidencias principales del repositorio

Repositorio del equipo: https://github.com/TaTan09/red-metropolitana. Los archivos listados corresponden a los resultados técnicos integrados en la rama main y permiten profundizar en métodos, decisiones, cifras y pruebas:

Apartado	Documento o evidencia
2.1 Modelos y métricas	docs/metricas/p2-21-ensemble.md; docs/evidencias/p2-21-ensemble.json
2.2 Umbral y test B	docs/metricas/p2-22/reporte.md; docs/evidencias/p2-22-test-b.json
2.3 Segmentación	docs/segmentacion_p2_23.md; docs/metricas/p2-23-segmentacion/
2.4 Guía y ficha	docs/README_P2_24.md; docs/modelo_ficha.md
2.4 Predicciones C	datos_red/p2-24-predicciones-c.csv
2.4 Invariancia	docs/evidencias/p2-24-invariancia-final.json